

人工智能数学基础样题

1. (10 分) (线性代数基础; 闭卷试题) 已知

$$u_1 = \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}, \quad u_2 = \begin{pmatrix} 1 \\ -1 \\ 2 \end{pmatrix}, \quad v = \begin{pmatrix} 2 \\ 0 \\ 1 \end{pmatrix}.$$

令 $U = \text{span}\{u_1, u_2\}$ 。

- (a) 判断 u_1 与 u_2 是否正交;
 - (b) 将 u_1, u_2 单位化, 写出由它们得到的一组标准正交向量组;
 - (c) 求向量 v 在子空间 U 上的正交投影 $\text{proj}_U(v)$;
2. (10 分) (概率论基础; 闭卷试题) 设连续型随机变量 X 的概率密度函数为

$$f(x) = \begin{cases} cx, & 0 < x < 1, \\ c(2-x), & 1 \leq x < 2, \\ 0, & \text{其他.} \end{cases}$$

回答下列问题:

- (a) 求常数 c , 并求出概率 $P(\frac{1}{2} < X < \frac{3}{2})$;
 - (b) 求随机变量 X 的数学期望 $E[X]$ 与方差 $\text{Var}(X)$;
3. (10 分) (概率论基础; 开卷试题) 某二分类任务的训练数据来自两个数据源 A 和 B 。随机抽取一个 mini-batch 时, 先随机选定数据源, 再从该数据源中独立抽取 2 个样本送入某个固定分类器进行预测。已知:
- 抽到数据源 A 的概率为 0.6, 抽到数据源 B 的概率为 0.4;
 - 对于来自数据源 A 的样本, 该分类器预测错误的概率为 0.1;
 - 对于来自数据源 B 的样本, 该分类器预测错误的概率为 0.2。

记事件 S_A 表示“该 mini-batch 来自数据源 A ”, S_B 表示“该 mini-batch 来自数据源 B ”; 记随机变量 X 表示这 2 个样本中被分类器预测错误的样本个数。

回答下列问题:

- (a) 求随机抽到的一个样本被该分类器预测错误的概率；
- (b) 求 $P(X = 0)$ ，即该 mini-batch 中 2 个样本都被正确分类的概率；
- (c) 已知这 2 个样本中恰有 1 个被错误分类，求该 mini-batch 来自数据源 B 的概率，即求 $P(S_B | X = 1)$ ；
- (d) 求随机变量 X 的数学期望 $E[X]$ 。
4. (10 分) (**最优化基础；闭卷试题**) 考虑一个简单的线性回归问题。设模型参数为

$$w = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \in \mathbb{R}^2,$$

对输入特征 $z \in \mathbb{R}^2$ 的预测为

$$\hat{y} = w^\top z.$$

现有两个训练样本：

$$z_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad y_1 = 2, \quad z_2 = \begin{pmatrix} 2 \\ -1 \end{pmatrix}, \quad y_2 = 0.$$

采用平方损失函数，则该线性回归模型在这两个样本上的经验风险为

$$f(x_1, x_2) = \frac{1}{2}(x_1 + x_2 - 2)^2 + \frac{1}{2}(2x_1 - x_2)^2.$$

回答下列问题：

- (a) 求函数 $f(x_1, x_2)$ 的梯度 $\nabla f(x)$ 与 Hessian 矩阵 $\nabla^2 f(x)$ ；
- (b) 判断 $f(x_1, x_2)$ 是否为凸函数，并说明理由；
- (c) 求该线性回归问题的最优解

$$x^* = (x_1^*, x_2^*)^\top;$$

- (d) 写出该问题的梯度下降法迭代格式。当取初始点

$$x^{(0)} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \quad \eta = \frac{1}{4},$$

求 $x^{(1)}$ 与 $x^{(2)}$ 。

5. (10 分) (**最优化基础；开卷试题**) 考虑二分类训练样本

$$\{(x_i, y_i)\}_{i=1}^m, \quad x_i \in \mathbb{R}^d, \quad y_i \in \{-1, +1\}.$$

硬间隔支持向量机的原问题为

$$\min_{w, b} \frac{1}{2} \|w\|_2^2 \quad \text{s.t.} \quad y_i(w^\top x_i + b) \geq 1, \quad i = 1, \dots, m.$$

回答下列问题：

- (a) 写出该优化问题的拉格朗日函数；
- (b) 对变量 w 和 b 分别写出驻点条件；
- (c) 由此推导该问题的对偶问题；
- (d) 说明如何由对偶最优解 α^* 恢复原问题中的 w^* ，并说明哪些样本点是支持向量。

6. (10 分)(大模型数学基础；闭卷试题) 回答下列问题：

- (a) 写出单头自注意力机制的数学表达式，包括如何计算 Query 矩阵 Q , Key 矩阵 K , Value 矩阵 V , 相似度得分矩阵 S , 权重矩阵 P 和输出矩阵 O ；
- (b) 设输入序列长度为 2，每个 token 的表示维度为 2。给定输入矩阵

$$X = \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix},$$

并设

$$W_Q = W_K = W_V = I_2.$$

对于这些给定的 X, W_Q, W_K, W_V ，计算 Q, K, V, S, P, O 的具体表达式。其中 softmax 不要求化为小数形式；

- (c) 当序列长度很长时，自注意力机制中哪个环节会成为主要的计算瓶颈和存储瓶颈？请简要说明原因。

7. (10 分)(大模型数学基础；开卷试题) LoRA (Low-Rank Adaptation) 技术是一项成熟的模型微调方式。这种方法的核心思想是通过向预训练好的模型中添加低秩分解的权重矩阵来实现对原始模型的微调，而不是直接调整模型原有的庞大参数集。假设我们有一个简化的神经网络：

$$x \xrightarrow{W_1} h \xrightarrow{\sigma(\cdot)} z \xrightarrow{W_2} y \xrightarrow{f(\cdot)} L$$

其中 $x \in \mathbb{R}^n$, $W_1 \in \mathbb{R}^{m \times n}$, $h \in \mathbb{R}^m$, $z \in \mathbb{R}^m$, $W_2 \in \mathbb{R}^{p \times m}$, $y \in \mathbb{R}^p$, $L \in \mathbb{R}$ ；

$$h = W_1 x, \quad z = \sigma(h), \quad y = W_2 z, \quad L = f(y),$$

其中 $\sigma(\cdot)$ 为激活函数，是一个元素级别的运算，即

$$z = \sigma(h) \iff z_i = \sigma(h_i), \quad i = 1, \dots, m.$$

且 $f: \mathbb{R}^p \rightarrow \mathbb{R}$ 为可导函数。

现假设该模型已完成预训练。为进行高效微调，我们引入四个低秩矩阵

$$A_1 \in \mathbb{R}^{m \times r}, \quad B_1 \in \mathbb{R}^{r \times n}, \quad A_2 \in \mathbb{R}^{p \times s}, \quad B_2 \in \mathbb{R}^{s \times m},$$


其中 $r \ll \min\{m, n\}$, $s \ll \min\{p, m\}$ 。我们将原先模型的线性层修改为

$$h = (W_1 + A_1 B_1)x, \quad y = (W_2 + A_2 B_2)z,$$

即

$$x \xrightarrow{W_1 + A_1 B_1} h \xrightarrow{\sigma(\cdot)} z \xrightarrow{W_2 + A_2 B_2} y \xrightarrow{f(\cdot)} L.$$

此时我们将 W_1, W_2 视为常数矩阵，而将 A_1, B_1, A_2, B_2 视为要学习的变量。当低秩增量矩阵初始为零（例如令 $A_1 B_1 = 0, A_2 B_2 = 0$ ）时，该修改后的模型便等效于原先的预训练模型，而进一步对 A_1, B_1, A_2, B_2 进行参数更新便可实现高效微调，此即为 LoRA。



(a) 请写出微调时的前反向传播过程，并求出

$$\frac{\partial L}{\partial A_2}, \quad \frac{\partial L}{\partial B_2}, \quad \frac{\partial L}{\partial A_1}, \quad \frac{\partial L}{\partial B_1}.$$

(b) 该模型预训练阶段需要学习的参数量是多少？使用 LoRA 进行微调时需要学习的参数量又是多少？LoRA 是否对参数量有所节省？

模式识别与机器学习样题

注：本题总体上适用于闭卷和开卷，但两者的难度有所不同

1. 简答题型（示例）

示例 1：请说明使用交叉验证方法进行模型选择的基本步骤。

示例 2：请简述一个典型模式识别系统的基本组成模块及各模块的功能。

示例 3：给定一个训练样本集 $T=\{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_n, y_n)\}$ ，机器学习模型 $f(\mathbf{x})$ 关于训练数据的平均损失称为经验风险或经验损失。在这里， $\mathbf{x}_i$ 表示样本特征， y_i 表示已知的真值。请给出一个有关经验损失的表达式。

示例 4：简述 PCA（主成分分析）的主要思想。给定一个训练样本集 $T=\{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_n, y_n)\}$ ，简述求解主成分的主要计算步骤。

示例 5：说明 Parzen 窗估计和 k 近邻（k-NN）概率密度估计方法有什么区别。

2. 计算题型（示例）

有下列 8 个二维空间的样本： $(-5, 1), (-2, 1), (-5, -1), (-2, -1), (5, 1), (2, 1), (5, -1), (2, -1)$ 。请按最小距离准则对上述 8 个样本进行分级聚类（即层次聚类），并画出分级聚类树图。

3. 推演题型（示例）：【基本的知识推演，但不含证明题】

示例 1：写出 Soft-Margin 支持向量机（SVM）的原问题和对偶问题，并在此基础上导出核支持向量机学习模型。

示例 2：给定目标损失函数和网络结构，推导误差反向传播算法。

4. 综合题型（示例）

某单位有 n 位职员，现从每位职员采集到一些人脸图像(可能因姿态、表情、光照条件的略微不同而不同)。每张人脸图像为 600(高度) $\times$ 400(宽度)像素大小的彩色图像。现需设计一个人脸识别系统，用于该单位的门禁和考勤。请回答以下问题：

(1)、描述拟采用的特征提取方法和分类器构造方法，分别给出其主要实现

步骤；

(2)、根据你所了解的相关技术前沿现状，对如何改进该单位的人脸识别系统的性能，给出一些建议。